

ВЕКТОРНЫЕ БАЗЫ ЗНАНИЙ

От PDF и OCR до hybrid search, RAG и
проверяемых ответов

**Практический учебник и справочник по mem-tool
1.21.0**

Автор проекта: Кнап Руслан Юрьевич

Редакция учебника 1.0 | 21 августа 2026

Локальная база знаний, технические документы, схемы и измеримые
рекомендации



Об этом руководстве

Этот документ объединяет фундаментальные принципы векторного поиска, практику подготовки PDF, OCR, chunking, dense и lexical retrieval, RAG и точные рекомендации для локальной программы mem-tool 1.21.0. Его задача - помочь не только выбрать три параметра конфигурации, но и понимать, почему система нашла или не нашла конкретный факт.

Главная мысль

Векторная база не хранит смысл вместо текста. Она хранит исходный текст, метаданные и числовое представление, которое помогает выбрать кандидатов. Проверяемость обеспечивают сохраненные страницы, блоки, фрагменты и ссылки на исходный документ.

Материал рассчитан на технические книги, журналы, справочники, инструкции, PDF со встроенным текстом и сканы. Примеры PowerShell ориентированы на Windows и текущий CLI/TUI mem-tool.

Обозначения: **C** - размер чанка; **O** - overlap; **k** - число возвращаемых результатов; **q** - вектор запроса; **d** - вектор документа.


Оглавление

Об этом руководстве	2
1. Картина целиком	4
1.1 Что именно находится в базе	4
1.2 Что база не гарантирует	4
2. Векторы и семантическая близость	5
2.1 Косинусная близость	5
2.2 Dense и sparse представления	5
2.3 BGE-M3 в mem-tool	5
3. PDF: извлечение важнее чанкинга	6
3.1 Три вида PDF	6
3.2 Что может исказиться	6
3.3 Настройки OCR в mem-tool	6
4. Chunking: как разрезать текст	7
4.1 Размер чанка C	7
4.2 Overlap O	7
4.3 Почему overlap не лечит все	8
5. Стратегии paragraph, sentence и fixed	8
5.1 paragraph	8
5.2 sentence	8
5.3 fixed	8
5.4 Быстрый выбор	9
6. Поиск: lexical, dense и fusion	9
6.1 Lexical-поиск	9
6.2 Dense-поиск	9
6.3 Fusion в mem-tool	9

7. RAG и проверяемые ответы	10
7.1 Fail-closed grounding mem-tool	10
7.2 Почему ссылка важнее уверенного тона	10
8. mem-tool 1.21.0: устройство и конфигурация	10
8.1 Локальная база	10
8.2 Текущий проверенный пример	11
8.3 Поля chunking	11
9. Рекомендуемые профили	11
9.1 Максимальная полнота технического PDF	11
9.2 Сбалансированная техническая книга	11
9.3 Связные объяснения	11
9.4 Каталоги и обозначения	12
9.5 Что выбрать сейчас	12
10. Практический рабочий процесс	12
10.1 Создание и импорт	12
10.2 Поиск	12
10.3 Ответ по evidence	12
10.4 Повторный импорт	12
11. Как измерять качество	13
11.1 Набор контрольных вопросов	13
11.2 Метрики	13
11.3 Матрица эксперимента	13
12. Диагностика проблем	13
12.1 Проверка границы	13
12.2 Проверка OCR	14
13. Безопасность, приватность и эксплуатация	14
13.1 Резервирование	14
14. Современные направления развития	14
14.1 Late chunking	14
14.2 Semantic chunking	14
14.3 Reranking	14
14.4 Exact phrase и таблицы	14
15. Краткая памятка	15
Приложение А. Полная конфигурация-пример	15
Приложение В. Чек-лист приемки документа	16
Глоссарий	16
Источники и дальнейшее чтение	17

1. Картина целиком

Путь информации: от документа к проверяемому ответу



Качество результата ограничено самым слабым звеном: OCR нельзя исправить настройкой `chunk_size`.

Рисунок 1. Полный конвейер знаний. Ошибка раннего этапа распространяется на все последующие.

Система поиска по документам состоит не из одной модели, а из цепочки преобразований. Пользовательский PDF сначала нужно прочитать. Затем текст связывается с физическими страницами, делится на фрагменты, переводится в векторы и сохраняется. Запрос проходит похожий путь: embedding запроса сравнивается с embedding фрагментов, lexical-поиск проверяет слова и числа, после чего лучшие evidence передаются answer-модели.

Не путать

Embedding-модель ищет близкие фрагменты. Answer-модель формулирует ответ. В mem-tool bge-m3 выполняет поиск, а отдельная chat/instruct-модель (например, gemma4) отвечает по выбранным evidence.

1.1 Что именно находится в базе

- Исходный текст каждого чанка без скрытого усечения.
- Dense-вектор, рассчитанный одной конкретной embedding-моделью.
- Lexical-индекс для слов, терминов и чисел.
- Путь к источнику, document ID, revision, page, block и chunk.
- Теги, заголовок, дата, embedding space и служебные хэши целостности.

1.2 Что база не гарантирует

- Она не восстанавливает символы, которые OCR распознал неправильно.
- Она не доказывает истинность исходного документа.
- Она не гарантирует 100% recall на любом запросе и любом наборе параметров.
- Она не заменяет открытие страницы и проверку первоисточника.
- Она не делает embedding разных моделей взаимозаменяемыми.

2. Векторы и семантическая близость

Embedding - это функция, которая преобразует текст в массив чисел фиксированной длины. У близких по смыслу текстов направления векторов часто оказываются близкими. Благодаря этому запрос может найти фрагмент без буквального совпадения слов. SBERT показал, как заранее вычисляемые sentence embeddings резко сокращают стоимость semantic similarity search по сравнению с попарным cross-encoder сравнением [1].

Косинусная близость сравнивает направление векторов




Рисунок 2. Геометрическая интуиция cosine similarity. Реальные векторы имеют сотни или тысячи измерений.

2.1 Косинусная близость

Косинус сравнивает угол между q и d . Значение 1 означает одинаковое направление, 0 - ортогональность, отрицательное значение - противоположное направление. Конкретная шкала релевантности зависит от модели и корпуса, поэтому универсального порога вроде 0.8 для всех баз не существует.

Практический вывод

Сравнивайте результаты одной модели внутри одной базы. При смене embedding-модели требуется переиндексация, потому что координатные пространства несовместимы.

2.2 Dense и sparse представления

Dense retrieval сжимает смысл в плотный вектор и хорошо работает с перефразированием. Sparse retrieval опирается на отдельные термины и частоты. DPR показал, что dense retriever может превосходить BM25 на ряде QA-наборов, но также отметил преимущество BM25 при сильном lexical overlap [2]. Поэтому практическая система часто объединяет оба сигнала.

Сигнал	Сильная сторона	Слабая сторона	Пример
Dense	Смысл, синонимы, перефразирование	Может пропустить редкий код или число	"усилитель мощности" -> "выходной каскад"
Lexical	Точные слова, обозначения, числа	Не понимает смысловой синоним	2N3866, 10.7 MHz, ГОСТ 12.1
Hybrid	Объединяет оба типа evidence	Нужно калибровать fusion и top-k	Технический поиск по книге

2.3 BGE-M3 в mem-tool

BGE-M3 поддерживает более 100 языков, dense, sparse и multi-vector режимы; официальный model card указывает размер dense-вектора 1024 и максимальную последовательность 8192 токенов [4][5]. В mem-tool через Ollama используется dense-вектор размерности 1024. Приложение намеренно ограничивает один embedding-фрагмент 2000 Unicode-символами, хотя сама модель допускает более длинный контекст. Это локальный защитный контракт программы, исключающий скрытое усечение.

Официальная документация Ollama рекомендует использовать одну и ту же embedding-модель для индексации и запросов и указывает cosine similarity как основной вариант semantic search [6].

3. PDF: извлечение важнее чанкинга

Пирамида качества



Если уровень 1 потерял символ, уровни 3-5 его не восстановят.

Рисунок 3. Пирамида качества. Настройки поиска не компенсируют потерю данных при извлечении.

3.1 Три вида PDF

Тип	Признак	Что делать
Text PDF	Текст выделяется мышью и копируется	Извлекать встроенный слой, проверять порядок колонок
Scan PDF	Каждая страница фактически изображение	Рендерить и выполнять OCR
Hybrid PDF	Часть страниц текстовая, часть сканы или плохой слой	Оценивать качество каждой физической страницы и OCR только плохие страницы

mem-tool анализирует физические страницы, сохраняет page provenance и использует локальные инструменты извлечения. Для OCR важны язык, разрешение, поворот, шум и сегментация. Документация Tesseract рекомендует изображения не ниже примерно 300 dpi и отдельно предупреждает о влиянии skew, шума, границ и неравномерного фона [10].

3.2 Что может исказиться

- Колонки могут соединиться в неправильном порядке.
- Таблица может превратиться в последовательность несвязанных ячеек.
- Формула может потерять индексы, дробную черту или греческий символ.
- 0/O, 1/I, 5/S, 8/B и кириллица/латиница могут перепутаться.
- Колонтитулы и номера страниц могут попасть внутрь основного текста.

Правило контроля

Перед массовым импортом откройте несколько rich-text, табличных и сканированных страниц. Проверьте начало, середину и конец документа, а также страницы с формулами и мелким шрифтом.

3.3 Настройки OCR в mem-tool

```
"ingest": {
  "ocr_languages": "rus+eng",
  "ocr_dpi": 300,
  "ocr_low_confidence": 65
}
```

`rus+eng` подходит для русско-английских технических текстов. `ocr\_dpi = 300` является разумной базовой точкой. Порог 65 не исправляет OCR, а помогает пометить низкую уверенность и не скрыть риск при последующем цитировании.

4. Chunking: как разрезать текст

Чанк - минимальная единица retrieval. Он должен быть достаточно коротким, чтобы embedding оставался конкретным, и достаточно длинным, чтобы содержать завершённый факт. Исследования chunk size показывают устойчивый компромисс: небольшие фрагменты лучше для коротких factoid-ответов, крупные - для вопросов с широким контекстом; оптимум зависит от корпуса и модели [9].

Пример: chunk_size = 800, overlap = 200, шаг = 600




Рисунок 4. Fixed-окна с перекрытием. Важная фраза около границы повторяется в соседнем чанке.

4.1 Размер чанка C

В mem-tool `chunk\_max\_size` измеряется в Unicode-символах (рунах), а не в байтах и не точно в токенах. Допустимый диапазон CLI - 100..2000. Локальная оценка `CountTokens` приблизительно делит число символов на 2, но реальное соотношение зависит от языка, формул и tokenizer модели.

С, символов	Назначение	Риски
500-700	Справочники, обозначения, короткие параметры	Мало контекста, много записей
800-1000	Технические книги и большинство PDF	Сбалансированный профиль
1200-1500	Связная проза и объяснения	Смысл может стать менее конкретным
1600-2000	Широкий контекст	Размывание темы, верхняя граница приложения

4.2 Overlap O

Overlap повторяет хвост предыдущего чанка в начале следующего. Для fixed-профиля шаг примерно равен `C - O`. Теоретическое число окон для текста длиной L можно оценить как $\lceil (L - C) / (C - O) \rceil + 1$. Относительное увеличение числа окон по сравнению с отсутствием overlap примерно равно $C / (C - O)$.

Доля O/C	Интерпретация	Оценка дополнительных окон
0%	Минимальная стоимость	0%
10%	Экономичный профиль	около 11%
20%	Хороший баланс	около 25%
25%	Максимальный охват границ	около 33%
> 30%	Обычно избыточное дублирование	быстрый рост

Особенность реализации

В paragraph и sentence overlap добавляется только в свободное место внутри max_size. Поэтому заданные 200 символов - верхняя цель, а не гарантия для каждого чанка. В fixed шаг С-О задается непосредственно и более предсказуем.

Защитное правило

Не задавайте overlap равным или большим chunk_size. Текущий алгоритм заменит такое значение примерно на 20% размера, но лучше хранить конфигурацию явно и без двусмысленности.

4.3 Почему overlap не лечит все

Overlap помогает фразам около границы, но не создает нового знания. В mem-tool страницы и provenance-блоки чанкуются отдельно, поэтому overlap не соединяет конец одной физической страницы с началом следующей. Он также не исправляет OCR и не гарантирует strict phrase search.

5. Стратегии paragraph, sentence и fixed

5.1 paragraph

Алгоритм разделяет текст по двум и более переводам строки, собирает абзацы до `max\_size`, длинный абзац режет по предложениям, а чрезмерно длинное предложение - фиксированно по границе слова. Это лучший первый выбор для качественно извлеченных книг, статей и Markdown.

Когда выбирать

Хороший text layer, сохраненные пустые строки, связная проза, явные разделы и абзацы.

5.2 sentence

Алгоритм ищет `.` , `!` , `?` , после которых следующее непустое слово начинается с заглавной буквы. Он сохраняет предложения целиком, пока они помещаются в лимит. Сокращения, OCR-ошибки, списки, формулы и текст без нормальной пунктуации снижают качество границ.

Когда выбирать

Хорошо распознанный учебный текст, где одно предложение обычно содержит заверченный факт. Не является универсальным выбором для таблиц и исходного кода.

5.3 fixed

Алгоритм берет предсказуемые окна длиной до `max\_size`, пытается разрезать по ближайшему пробелу во второй половине окна. Следующая позиция смещается назад на overlap. Это самый надежный режим для покрытия границ в плохо структурированном OCR, каталогах, таблицах и технических PDF.

Цена предсказуемости

Fixed может разорвать предложение и смешать соседние смысловые блоки. Компенсация - overlap 15-25% и hybrid search.

5.4 Быстрый выбор

Документ	Стратегия	С	О	Почему
Техническая книга с хорошими абзацами	paragraph	1000	180	Смысловые блоки сохраняются
Сканированный справочник	fixed	800	200	Предсказуемый охват
Каталог деталей и обозначений	fixed	650	160	Точная локализация
Связная статья	paragraph	1200-1400	200-220	Больше контекста
Короткие факты в предложениях	sentence	700-900	120-160	Сохраняет фразу целиком

6. Поиск: lexical, dense и fusion

Hybrid search в mem-tool




Рисунок 5. Два независимых сигнала объединяются до окончательного top-k.

6.1 Lexical-поиск

SQLite FTS5 - модуль полнотекстового поиска. Он токенизирует текст, поддерживает phrase syntax и ранжирование BM25 [7]. В текущем mem-tool запрос программно превращается в набор quoted-токенов, соединенных `AND`. Поэтому все слова должны находиться в одном чанке, но их строгий порядок как у phrase query не проверяется.

Практически это означает: для номера детали, частоты или короткого термина используйте короткий запрос. Длинный разговорный вопрос может быть слишком строгим для lexical-ветки, хотя dense-ветка продолжит работать.

6.2 Dense-поиск

Dense-поиск сравнивает embedding запроса со всеми совместимыми embedding чанков. Он позволяет находить смысловые аналоги, но может недооценить редкое обозначение. Размер чанка влияет на плотность смысла: чем больше тем в одном фрагменте, тем менее конкретно его направление.

6.3 Fusion в mem-tool

Текущая формула объединяет нормализованные компоненты поровну: ``0.5 * vector_score + 0.5 * lexical_score``. Затем применяется rerank и пользовательские фильтры. Флаг ``-vector-only`` отключает lexical-кандидатов, поэтому для максимального recall технических терминов его обычно использовать не следует.

```

mem search "2N3866" -limit 20
mem search "Solenoid Design" -limit 20
mem search "угол проводимости" -limit 20
mem ask "Каковы особенности усилителя класса C?" -limit 10
  
```

Принцип диагностики

Сначала выполните mem search и посмотрите сырые чанки. Только после подтверждения retrieval используйте mem ask. Если нужного evidence нет в search, answer-модель не должна его придумывать.

7. RAG и проверяемые ответы

Retrieval-Augmented Generation объединяет parametric memory модели с внешней non-parametric memory - индексом документов [3]. В практической системе retriever сначала выбирает evidence, затем генератор формулирует ответ. Это снижает зависимость от памяти модели, но не отменяет ошибки retrieval и генерации.

7.1 Fail-closed grounding mem-tool

- 1 По вопросу строится embedding и выполняется hybrid retrieval.
- 2 Фрагментам назначаются короткие внутренние ссылки E1, E2 и так далее.
- 3 Модель обязана вернуть JSON claims, где у каждого утверждения есть citations.
- 4 Программа проверяет формат, известность ссылок и целостность evidence.
- 5 Только после проверки пользователь видит утверждения с ссылками вида [1, стр. 222].

Длинные SHA-256 citation ID, document revision и evidence hash остаются внутри механизма проверки, но не загромождают обычный вывод. Человек получает название PDF, полный путь, физическую страницу, блок и фрагмент.

Усилитель класса С имеет угол проводимости менее 180° . [1, стр. 222]

Источники:

[1] Radio Frequency Circuit Design.pdf
Файл: D:\...\Radio Frequency Circuit Design.pdf
Место: страница 222 · блок 222 · фрагмент 1/3

7.2 Почему ссылка важнее уверенного тона

Модель может писать грамотно и уверенно даже при ошибке. Поэтому надежный ответ определяется не стилем, а возможностью открыть источник и проверить утверждение. Для формул, норм, мер безопасности и числовых параметров ручная проверка обязательна.

Граница доверия

Ссылка доказывает, откуда взят фрагмент. Она не доказывает, что модель правильно его интерпретировала и что сам документ верен.

8. mem-tool 1.21.0: устройство и конфигурация

8.1 Локальная база

Обычный `mem` использует `.mem` в текущем каталоге PowerShell. Расположение `mem.exe` в PATH не влияет на выбор базы. `mem where` показывает фактические пути, `mem open` переключает TUI на существующую локальную базу.

```
cd E:\temp\mem-test2
mem where
mem stats
mem sources
mem config
```

8.2 Текущий проверенный пример

Параметр	Значение
База	E:\temp\mem-test2\mem\store.db
Документ	Radio Frequency Circuit Design.pdf
Записей / чанков	774 / 774
Embedding	Ollama, bge-m3, 1024 измерения
Chunking	paragraph, C=1000, O=100
Answer model	gemma4:cloud

Этот профиль уже дает корректные ответы со ссылками на страницы 222 и 226. Однако для максимального охвата фраз на границах технического PDF ниже рекомендован более консервативный fixed-профиль.

8.3 Поля chunking

```
"chunking": {
  "chunk_max_size": 800,
  "chunk_overlap": 200,
  "chunk_strategy": "fixed"
}
```

Поле	Единица	CLI-диапазон	Роль
chunk_max_size	Unicode-символы	100..2000	Верхний размер одного embedding-фрагмента
chunk_overlap	Unicode-символы	0..1000	Повтор контекста между соседями
chunk_strategy	режим	paragraph/sentence/fixed	Правило определения границы

Конфигурация применяется к будущему импорту. Уже сохраненные chunks автоматически не перестраиваются. Повторный `mem import` того же документа создает embeddings, а затем атомарно заменяет предыдущую ревизию только при полном успехе.

9. Рекомендуемые профили

9.1 Максимальная полнота технического PDF

```
mem config set-chunk-size 800
mem config set-chunk-overlap 200
mem config set-chunk-strategy fixed
```

Используйте для справочников, схемотехники, OCR, таблиц, формул и документов с плохой структурой. Шаг около 600 символов, теоретический рост числа окон примерно 33% относительно O=0. Это основной профиль для требования «не упускать фразы и параметры».

9.2 Сбалансированная техническая книга

```
mem config set-chunk-size 1000
mem config set-chunk-overlap 180
mem config set-chunk-strategy paragraph
```

Используйте при хорошем text layer и нормальных абзацах. Он дает более связные evidence и меньше дубликатов, чем fixed 800/200.

9.3 Связные объяснения

```
mem config set-chunk-size 1400
mem config set-chunk-overlap 220
mem config set-chunk-strategy paragraph
```

Подходит для учебных глав и вопросов «объясни принцип». Для редких кодов и коротких параметров обязательно сохраняйте hybrid search.

9.4 Каталоги и обозначения

```
mem config set-chunk-size 650
mem config set-chunk-overlap 160
mem config set-chunk-strategy fixed
```

Высокая локализация, но больше чанков и меньше контекста. Проверьте, что `answer -limit` возвращает несколько соседних фрагментов.

9.5 Что выбрать сейчас

Рекомендация для ARRL Handbook

Начните с `fixed`, `C=800`, `O=200`. Сохраните 15-20 контрольных запросов. Затем сравните с `paragraph`, `C=1000`, `O=180` на отдельной тестовой базе. Выбирайте по `Recall@k` и проверяемости ответов, а не по субъективному впечатлению от одного запроса.

10. Практический рабочий процесс

10.1 Создание и импорт

```
mkdir E:\knowledge\radio-handbook
cd E:\knowledge\radio-handbook
mem init

mem config set-chunk-size 800
mem config set-chunk-overlap 200
mem config set-chunk-strategy fixed

mem import "D:\Books\Radio Frequency Circuit Design.pdf" -tags "RF,ARRL"
mem stats
mem sources
```

Пути с пробелами всегда заключайте в кавычки. До итогового `[OK] Документ импортирован` новая версия документа не появляется в базе.

10.2 Поиск

```
mem search "класс C" -limit 20
mem search "угол проводимости" -tags "RF,ARRL" -limit 20
mem search "2 GHz" -limit 20
```

Для максимального `recall` используйте несколько формулировок: термин, синоним, английское написание и числовое обозначение. Не смешивайте в одном `lexical`-запросе слишком много необязательных слов.

10.3 Ответ по evidence

```
mem ask "Каковы особенности усилителя класса C?" -limit 10
mem ask "Какие параметры используются при расчете соленоида до 2 GHz?" -limit 10
```

Проверьте, что каждый важный тезис имеет `[N, стр. X]`, а источник содержит ожидаемый PDF и физическую страницу. Для спорного числа откройте документ и сравните с оригиналом.

10.4 Повторный импорт

После изменения `chunking` повторите импорт с тем же путем. Не сравнивайте две настройки внутри одной и той же базы после замены. Для честного A/B теста создайте две отдельные директории, импортируйте один PDF и используйте одинаковый набор запросов.

11. Как измерять качество

11.1 Набор контрольных вопросов

Составьте минимум 20-50 вопросов до настройки. Включите разные типы: точный термин, число, определение, связь двух фактов, таблица, формула, страница со сканом, русский запрос к английскому источнику и вопрос без ответа в документе.

11.2 Метрики

Метрика	Вопрос	Как считать
Recall@k	Попал ли нужный чанк в top-k?	Доля вопросов, где evidence найден
MRR	Насколько высоко первый правильный результат?	Среднее 1/rank
Citation accuracy	Правильна ли страница?	Доля корректных ссылок
Answer support	Подтвержден ли каждый claim?	Ручная проверка claims
OCR defect rate	Сколько символов и формул искажено?	Выборочная сверка страниц
Cost	Сколько времени и места требуется?	chunks, импорт, размер store.db

11.3 Матрица эксперимента

Профиль	Стратегия	C	O	Recall@10	Citation	Время
A	fixed	800	200	___ / 30	___ / 30	___
B	paragraph	1000	180	___ / 30	___ / 30	___
C	paragraph	1400	220	___ / 30	___ / 30	___

Стоп-условие

Не оптимизируйте по одному красивому ответу. Если профиль улучшает один вопрос, но ухудшает Recall@10 на контрольном наборе, он не является общим улучшением.

12. Диагностика проблем

Симптом	Вероятная причина	Действие
Нужное слово не находится	OCR-ошибка или другой символ	Проверить source, варианты 0/O, рус/лат, поиск части термина
Смысловой вопрос дает шум	Чанк слишком большой	Уменьшить C, использовать paragraph/fixed, повторный импорт
Ответу не хватает контекста	Чанк слишком мал или top-k мал	Увеличить C, overlap, -limit или answer context
Много одинаковых результатов	Overlap слишком велик	Уменьшить O или C, сравнить recall
PDF дал 0 chunks	Нет текста и OCR не сработал	Проверить инструменты, язык, DPI и warnings
После config ничего не изменилось	Старые chunks не перестроены	Повторно импортировать документ
ask отвечает без нужного факта	Retriever не вернул evidence	Сначала mem search, затем изменить запрос/профиль

12.1 Проверка границы

Выберите фразу, расположенную около предполагаемой границы чанка. Найдите ее первую и последнюю половину отдельно. Если обе части встречаются, но ни один результат не содержит фразу целиком, увеличьте overlap или используйте fixed.

12.2 Проверка OCR

Сравните физическую страницу, извлеченный source-chunk и ответ. Ошибка уже в source-chunk означает проблему OCR/extraction. Правильный source-chunk, который не попал в search, означает retrieval-проблему. Правильный evidence и неверный ответ означает generation/interpretation-проблему.

13. Безопасность, приватность и эксплуатация

- Локальный Ollama endpoint ограничивает передачу evidence loopback-адресом, но модель с тегом `cloud` может отправлять prompt через Ollama Cloud.
- Не импортируйте секреты в облачный workflow без понимания политики данных.
- Не копируйте открытый store.db как единственную резервную копию. Сначала закройте процессы или используйте согласованный backup-процесс SQLite.
- Храните исходный PDF. База и embeddings не заменяют оригинал.
- При смене модели создавайте новый embedding space или выполняйте полную переиндексацию.

Данные evidence

mem ask передает answer-модели не весь PDF, а отобранные фрагменты с метаданными. Тем не менее эти фрагменты могут содержать конфиденциальный текст.

13.1 Резервирование

Минимальный комплект резервной копии: исходные документы, каталог `.mem`, версия программы, config.json и описание embedding-модели. Без модели или совместимого embedding space сохраненные векторы могут стать непригодными для новых запросов.

14. Современные направления развития

14.1 Late chunking

Обычный подход кодирует каждый чанк отдельно и может потерять контекст окружающих фрагментов. Late Chunking сначала обрабатывает длинный контекст трансформером, а деление выполняет перед pooling; авторы сообщают улучшения retrieval на нескольких задачах [8]. Текущий mem-tool использует обычный independent chunk embedding, поэтому overlap остается практической компенсацией.

14.2 Semantic chunking

Semantic chunking ищет смену темы по embedding предложений или структуре документа. Он может давать более естественные блоки, но сложнее, дороже и требует воспроизводимой настройки. Для provenance-first системы важнее сначала гарантировать стабильные страницы, отсутствие потерь и измеримый baseline fixed/paragraph.

14.3 Reranking

Cross-encoder reranker глубже сравнивает запрос и небольшой набор кандидатов, но слишком дорог для полного корпуса. Типичная архитектура: быстрый dense/sparse retrieval -> union candidates -> reranker -> top-k. Это возможное направление развития после появления надежного evaluation-набора.

14.4 Exact phrase и таблицы

Будущие улучшения могут включать отдельный phrase/substring режим FTS5, trigram tokenizer, таблицы как структурированные объекты и соседние page-context windows. Их следует добавлять с тестами, чтобы не ухудшить текущий hybrid recall.

15. Краткая памятка

Цель	Настройка / действие
Максимальный охват технического PDF	fixed, C=800, O=200
Хорошие абзацы и связный текст	paragraph, C=1000, O=180
Больше контекста для объяснений	paragraph, C=1400, O=220
Точные обозначения и каталоги	fixed, C=650, O=160 + короткий lexical query
Ничего не находится	Проверить OCR/source до изменения chunking
Изменили config	Повторно импортировать документ
Нужна проверяемость	Открыть источник по [N, стр. X]
Нужен честный выбор	A/B базы + 20-50 вопросов + Recall@k

Рекомендуемый старт

Для Radio Frequency Circuit Design.pdf: fixed, C=800, O=200; rus+eng; OCR 300 dpi; hybrid search без -vector-only; ask -limit 10; ручная проверка чисел и формул по странице.

Приложение А. Полная конфигурация-пример

```
{
  "backend": "ollama",
  "ollama": {
    "base_url": "http://localhost:11434",
    "model": "bge-m3"
  },
  "answer": {
    "base_url": "http://localhost:11434",
    "model": "gemma4:cloud",
    "timeout_seconds": 60,
    "max_tokens": 512,
    "context_chars": 12000,
    "temperature": 0.1
  },
  "chunking": {
    "chunk_max_size": 800,
    "chunk_overlap": 200,
    "chunk_strategy": "fixed"
  },
  "ingest": {
    "ocr_languages": "rus+eng",
    "ocr_dpi": 300,
    "ocr_low_confidence": 65
  }
}
```

Если используется `gemma4:cloud`, retrieved evidence может передаваться через Ollama Cloud. Для полностью локальной обработки выберите установленную chat/instruct-модель без cloud-тега.

Приложение В. Чек-лист приемки документа

- 1 ``mem where`` показывает ожидаемый store.db.
- 2 ``mem import`` завершился сообщением ``[OK]``, без скрытых ошибок.
- 3 ``mem stats`` показывает ожидаемое число chunks.
- 4 ``mem sources`` показывает один актуальный документ и правильный путь.
- 5 Проверены text-rich, scanned, table, formula и boundary страницы.
- 6 Точные коды и числа находятся короткими ``mem search`` запросами.
- 7 Перефразированные вопросы находят смысловые фрагменты.
- 8 Негативный вопрос корректно возвращает недостаточность evidence.
- 9 Каждый важный claim содержит ссылку ``[N, стр. X]``.
- 10 Страница и текст вручную сверены минимум для 10-15 ответов.

Дата	Документ / ревизия	Профиль	Вопросов	Recall@10	Ошибки OCR	Решение
_____	_____	_____	_____	_____	_____	_____
_____	_____	_____	_____	_____	_____	_____
_____	_____	_____	_____	_____	_____	_____

Глоссарий

Термин	Определение
Answer model	Chat/instruct-модель, формулирующая ответ по evidence.
BM25	Функция ранжирования полнотекстового поиска по терминам и частотам.
Chunk	Фрагмент исходного текста, единица индексации и retrieval.
Cosine similarity	Мера сходства направлений двух векторов.
Dense retrieval	Поиск по плотным семантическим векторам.
Embedding	Числовое представление текста фиксированной размерности.
Embedding space	Координатное пространство конкретной модели и конфигурации.
Evidence	Фрагмент источника, переданный модели как основание ответа.
FTS5	Модуль полнотекстового поиска SQLite.
Grounding	Ограничение ответа найденными и проверенными источниками.
Hybrid search	Объединение dense и lexical сигналов.
OCR	Оптическое распознавание текста на изображении страницы.
Overlap	Повтор части текста в соседних чанках.
Precision	Доля релевантных элементов среди найденных.
Provenance	Происхождение: документ, ревизия, страница, блок, фрагмент.
RAG	Генерация ответа с retrieval внешних документов.
Recall	Доля нужных элементов, которые удалось найти.
Reranking	Повторное более точное ранжирование небольшого списка кандидатов.
Sparse retrieval	Поиск по разреженным признакам слов и терминов.
Top-k	Количество лучших результатов, передаваемых следующему этапу.

Источники и дальнейшее чтение

- [1] N. Reimers, I. Gurevych. Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. EMNLP 2019.
<https://arxiv.org/abs/1908.10084>
- [2] V. Karpukhin et al. Dense Passage Retrieval for Open-Domain Question Answering. 2020.
<https://arxiv.org/abs/2004.04906>
- [3] P. Lewis et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. 2020.
<https://arxiv.org/abs/2005.11401>
- [4] J. Chen et al. BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity. 2024.
<https://arxiv.org/abs/2402.03216>
- [5] BAAI. BGE-M3 model card: 1024 dimensions, sequence length 8192.
<https://huggingface.co/BAAI/bge-m3>
- [6] Ollama official documentation: Embeddings, cosine similarity and model consistency.
<https://docs.ollama.com/capabilities/embeddings>
- [7] SQLite official documentation: FTS5, tokenizers, phrases and BM25.
<https://www.sqlite.org/fts5.html>
- [8] M. Günther et al. Late Chunking: Contextual Chunk Embeddings Using Long-Context Embedding Models. v3, 2025.
<https://arxiv.org/abs/2409.04701>
- [9] S. R. Bhat et al. Rethinking Chunk Size For Long-Document Retrieval: A Multi-Dataset Analysis. 2025.
<https://arxiv.org/abs/2505.21700>
- [10] Tesseract OCR documentation: Improving the quality of the output.
<https://tesseract-ocr.github.io/tessdoc/ImproveQuality.html>
- [11] mem-tool source and project documentation.
<https://github.com/knaprus-14/mem-tool>

Все внешние источники проверены 21 августа 2026 года. Рекомендации для mem-tool дополнительно сверены с локальным исходным кодом версии 1.21.0 и реальной тестовой базой пользователя.